



Casa abierta al tiempo

Universidad Autónoma Metropolitana

Azcapotzalco

División de Ciencias Básicas e Ingeniería

Análisis de similitud de contenidos entre programas de UEA

Proceso de modificación curricular 2026 — DCBI

Índice

1. Introducción	2
2. Metodología	2
2.1. El problema: comparar 626 textos técnicos cortos	2
2.2. El modelo del espacio vectorial	2
2.3. Ponderación TF-IDF	3
2.4. Similitud coseno	3
2.5. Exclusión del Tronco General	4
2.6. Agrupamiento jerárquico de Ward	4
2.7. Proyección bidimensional: t-SNE	5
2.8. Agregación media-máxima entre licenciaturas	5
2.9. Enriquecimiento semántico con LLM	6
3. Corpus analizado	6
4. Análisis inter-plan	7
4.1. Similitud media-máxima entre planes	8
4.2. Recuento de UEAs equivalentes: los 45 pares	8
4.3. Red de traslape	10
4.4. UEAs con mayor presencia transversal	10
4.5. Pares individuales de mayor similitud	11
5. Análisis intra-plan	12
5.1. Pares y casos más relevantes	13
5.2. Mapas de calor intra-plan	13
6. Mapa de calor agrupado	24
7. Proyección t-SNE	25
8. Hallazgos principales	25
8.1. Hallazgos inter-plan	26
8.2. Hallazgos intra-plan	27
9. Observaciones y recomendaciones	28

1 Introducción

El proceso de modificación curricular 2026 de la División CBI implica la revisión simultánea de 773 programas de Unidades de Enseñanza-Aprendizaje (UEA) distribuidos en las diez licenciaturas de la División. Una de las tareas centrales es identificar si distintos programas de diferentes licenciaturas cubren contenido equivalente o sustancialmente solapado—información indispensable tanto para proponer unificaciones al Tronco General como para detectar duplicaciones implícitas entre planes de estudio que se ofrecen de manera independiente.

El presente reporte documenta el análisis cuantitativo de similitud de contenidos sobre el corpus de 626 UEAs resultante tras excluir el Tronco General. El análisis opera en dos fases. En la primera, los campos *Objetivo General* y *Contenido Sintético* de cada programa se representan como vectores TF-IDF en un espacio de 8 000 dimensiones y se calcula la similitud coseno entre cada par, produciendo una matriz inicial de 626×626 entradas. En la segunda, todos los pares con $s_{\text{TF-IDF}} \geq 0.20$ (1 505 pares candidatos) son evaluados por el modelo de lenguaje *claude-haiku-4-5*, que devuelve una puntuación semántica revisada $s_{\text{LLM}} \in [0, 1]$ y una justificación en español. El resultado es la *matriz híbrida*: más precisa que TF-IDF solo porque corrige falsos positivos (vocabulario genérico compartido sin equivalencia real de contenidos) y falsos negativos (programas idénticos con redacciones léxicamente distintas).

Todos los resultados de este reporte—tablas, mapas de calor, grafo, proyección t-SNE—proviene de la matriz híbrida. Las figuras interactivas están disponibles en el sitio web del proyecto:

<https://cslmuam.github.io/similitud-dcbi-2026/>

donde cada visualización puede consultarse en el navegador, con identificación de UEAs individuales al pasar el cursor.

2 Metodología

2.1 El problema: comparar 626 textos técnicos cortos

Cada programa de UEA consiste en 150 a 500 palabras distribuidas entre los campos *Objetivo General* y *Contenido Sintético*. La tarea es detectar, entre los $\binom{626}{2} = 195\,375$ pares posibles, aquellos cuyo contenido declarado es sustancialmente equivalente. La comparación manual es inviable a esa escala; se requiere una medida cuantitativa de similitud que sea calculable automáticamente, interpretable sin conocimiento previo del sistema, y robusta frente a la heterogeneidad de estilos de redacción entre programas.

Los programas presentan tres características que determinan las elecciones metodológicas: son *cortos* (representaciones esparsas), están escritos en *español técnico* (vocabulario especializado, bigramas informativos), y provienen de un corpus de tamaño *pequeño a mediano* (626 documentos) sin ningún tipo de anotación previa.

2.2 El modelo del espacio vectorial

El punto de partida es el *modelo del espacio vectorial* (VSM, del inglés *Vector Space Model*) propuesto por Salton and McGill (1983). La idea central es asignar a cada documento d un vector $\mathbf{v}_d \in \mathbb{R}^{|V|}$, donde $|V|$ es el tamaño del vocabulario y la k -ésima coordenada refleja la relevancia del k -ésimo término para ese documento. La similitud entre dos documentos se reduce entonces a un problema geométrico: la comparación de dos vectores en un espacio euclidiano de alta dimensión.

El VSM es la base de la recuperación de información moderna (Manning et al., 2008) y proporciona la fundamentación para los pasos subsecuentes: la elección de las coordenadas (TF-IDF) y de la métrica de comparación (similitud coseno).

2.3 Ponderación TF-IDF

La elección más simple para las coordenadas sería la frecuencia bruta $f_{t,d}$ de cada término t en el documento d . Esta elección es inadecuada por dos razones. Primero, viola la ley de Zipf: en cualquier corpus natural, unos pocos términos son extremadamente frecuentes y poco discriminativos (“ecuaciones”, “análisis”, “sistemas”), mientras que los términos técnicamente específicos son raros. Un vector de frecuencias brutas estará dominado por términos genéricos. Segundo, documentos más largos producen coordenadas sistemáticamente más grandes, sesgando la comparación.

La ponderación TF-IDF (*Term Frequency–Inverse Document Frequency*) corrige ambos problemas. El peso del término t en el documento d es (Salton and Buckley, 1988)

$$w_{t,d} = (1 + \log f_{t,d}) \log \frac{N}{n_t}, \quad (1)$$

donde $f_{t,d}$ es la frecuencia del término en el documento, $N = 626$ es el tamaño total del corpus y n_t es el número de documentos en que t aparece.

El factor $1 + \log f_{t,d}$ en la ecuación (1) comprime la escala de frecuencias mediante un logaritmo: la diferencia de relevancia entre una aparición y diez es mucho menor que la diferencia entre cero y una. El factor $\log(N/n_t)$ es la *frecuencia inversa de documento* (IDF), introducido por Sparck Jones (1972). Su motivación es directamente probabilística: si un término aparece en casi todos los documentos, es informativamente vacío; si aparece en pocos, es altamente discriminativo. Robertson (2004) provee la justificación bayesiana formal de esta intuición: el IDF puede derivarse como logaritmo de la razón de verosimilitudes de encontrar el término en un documento relevante versus uno irrelevante.

Se excluyen del vocabulario los términos genéricos (*stopwords* académicas: “objetivo”, “contenido”, “estudiante”, etc.) y los términos que aparecen en menos de dos documentos o en más del 85 % del corpus, y se incluyen bigramas—secuencias de dos palabras contiguas como “ecuaciones diferenciales” o “transferencia de calor”—para capturar frases técnicas compuestas (Manning et al., 2008, cap. 2). El vocabulario resultante comprende hasta 8 000 términos y bigramas.

La razón para preferir TF-IDF sobre las representaciones neurales densas (BERT, modelos de lenguaje) en esta primera fase es triple. *Interpretabilidad*: cada coordenada de un vector TF-IDF corresponde a un término específico, de modo que la similitud entre dos programas es explicable en términos del vocabulario técnico que comparten. *Robustez para corpus pequeños*: los modelos neuronales requieren ajuste fino en el dominio específico; con 626 documentos y vocabulario técnico en español, TF-IDF produce representaciones más estables (Turney and Pantel, 2010). *Ausencia de datos etiquetados*: no existe un conjunto de pares de UEAs etiquetados manualmente como “equivalentes”, lo que impide el aprendizaje supervisado.

2.4 Similitud coseno

Dada la representación vectorial, se necesita una métrica de comparación. La distancia euclidiana $\|\mathbf{v}_{d_i} - \mathbf{v}_{d_j}\|$ depende de la magnitud de los vectores: un programa de 500 palabras tendrá coordenadas más grandes que uno de 150 palabras sobre el mismo tema, y su distancia euclidiana a cualquier otro programa será sistemáticamente mayor—un sesgo indeseable.

La similitud coseno elimina este sesgo midiendo el ángulo entre vectores en lugar de la distancia entre sus extremos:

$$s(d_i, d_j) = \frac{\mathbf{v}_{d_i} \cdot \mathbf{v}_{d_j}}{\|\mathbf{v}_{d_i}\| \|\mathbf{v}_{d_j}\|}, \quad (2)$$

donde $\mathbf{v}_d \in \mathbb{R}^{8000}$ es el vector TF-IDF normalizado a la unidad (Manning et al., 2008, cap. 6). Dado que los pesos TF-IDF son no negativos, la similitud coseno en la ecuación (2) toma valores en $[0, 1]$. El valor $s = 1$ implica que los dos programas tienen exactamente el mismo perfil de términos relevantes; el valor $s = 0$ implica que no comparten ningún término significativo.

La interpretación práctica de los valores se resume en la siguiente escala:

Rango	Nivel	Significado
[0.00, 0.30)	Sin traslape	Contenidos esencialmente distintos
[0.30, 0.45)	Bajo	Vocabulario técnico parcialmente compartido
[0.45, 0.65)	Moderado	Traslape de contenidos significativo
[0.65, 0.85)	Alto	Contenidos ampliamente solapados
[0.85, 1.00]	Muy alto	Programas casi idénticos o idénticos

2.5 Exclusión del Tronco General

Las UEAs del Tronco General comparten programa por definición, por lo que incluirlas en el análisis produciría pares trivialmente idénticos que contaminarían las métricas de traslape entre licenciaturas. Se excluyen del corpus mediante tres criterios independientes.

Criterio I (frecuencia de clave). Se excluye toda UEA cuya clave aparece en siete o más de las diez licenciaturas. Este umbral es una heurística operacional adoptada para el análisis—no corresponde a ningún artículo del RES—y se justifica porque las UEAs del Tronco General vigente aparecen en todas o casi todas las licenciaturas. Con este criterio se detectaron 7 claves.

Criterio II (frecuencia de nombre). Se excluye toda UEA cuyo nombre normalizado (sin acentos, en minúsculas) aparece en siete o más licenciaturas. Esto detectó 10 nombres adicionales—entre ellos *Cultura de Paz y Género*, que en distintas licenciaturas tiene claves diferentes.

Criterio III (rol estructural). Se excluyen mediante expresiones regulares las UEAs de integración (*Proyecto o Seminario de Integración*), *Temas Selectos*, movilidad y prácticas profesionales.

El corpus resultante tras las exclusiones comprende **626 programas de UEA**.

2.6 Agrupamiento jerárquico de Ward

La matriz de similitud 626×626 resultante contiene información sobre todos los pares. Para visualizarla como mapa de calor es necesario reordenar filas y columnas de modo que las UEAs de contenido similar queden adyacentes—de lo contrario el mapa es ruido visual. Este reordenamiento se obtiene mediante el *agrupamiento jerárquico aglomerativo de Ward* (Ward, 1963).

El método parte del conjunto donde cada UEA forma su propio grupo y fusiona iterativamente los dos grupos cuya unión incrementa mínimamente la varianza intra-cluster total. El criterio de fusión de Ward entre dos grupos C_i y C_j es:

$$\Delta E(C_i, C_j) = \frac{n_i n_j}{n_i + n_j} \|\boldsymbol{\mu}_i - \boldsymbol{\mu}_j\|^2, \quad (3)$$

donde n_i, n_j son los tamaños y μ_i, μ_j son los centroides de cada grupo. Minimizar ΔE en la ecuación (3) equivale a minimizar la suma total de cuadrados intra-cluster (Murtagh and Legendre, 2014), criterio que produce grupos compactos y bien separados.

La razón para elegir Ward frente a otros criterios de enlace (completo, promedio, simple) es que estos últimos presentan el *efecto de encadenamiento*: un único par de UEAs con alta similitud puede conectar artificialmente dos grupos temáticamente distintos. Ward penaliza las fusiones que aumentan la heterogeneidad interna, produciendo un dendrograma cuya estructura refleja mejor la organización temática del corpus. Murtagh and Legendre (2014) demuestran que el criterio de Ward es el único de los métodos aglomerativos clásicos que minimiza una función objetivo global bien definida.

El algoritmo se aplica a la matriz de *distancias* $1 - s(d_i, d_j)$, derivada de la similitud coseno; el orden de las hojas del dendrograma resultante se usa como permutación de filas y columnas del mapa de calor.

2.7 Proyección bidimensional: t-SNE

El espacio TF-IDF de 8 000 dimensiones no puede visualizarse directamente. El análisis de componentes principales (PCA) produciría una proyección lineal que captura la varianza global pero no la estructura de grupos locales: en espacios de alta dimensión, los datos viven frecuentemente en variedades no lineales que PCA no puede desplegar.

El método t-SNE (*t-distributed Stochastic Neighbor Embedding*) de van der Maaten and Hinton (2008) resuelve este problema modelando explícitamente la estructura de *vecindades locales*. En el espacio de alta dimensión, define la probabilidad p_{ij} de que dos documentos sean vecinos mediante una distribución gaussiana centrada en cada punto. En la proyección bidimensional, define las probabilidades análogas q_{ij} mediante una distribución de Student con un grado de libertad—cola más pesada que la gaussiana. El algoritmo minimiza la divergencia de Kullback–Leibler $KL(P \parallel Q)$ entre ambas distribuciones de probabilidad, forzando que los vecinos en el espacio original lo sean también en el plano.

La cola pesada de la distribución de Student en la proyección resuelve el *problema de aglomeración* (*crowding problem*): en alta dimensión, muchos puntos pueden estar a distancia moderada de un punto central; en dos dimensiones no hay espacio suficiente para todos ellos si se usan distribuciones de colas ligeras, lo que produce mapas comprimidos e ilegibles (van der Maaten and Hinton, 2008). La distribución de Student permite que los puntos alejados en alta dimensión se separen ampliamente en el plano, produciendo proyecciones con grupos bien diferenciados (Wattenberg et al., 2016).

Por recomendación explícita de van der Maaten and Hinton (2008), la proyección se aplica en dos etapas: primero se reduce el espacio a 50 componentes principales con PCA—eliminando dimensiones de ruido y acelerando el cálculo—y sobre ese espacio de 50 dimensiones se ejecuta t-SNE. Los parámetros usados son perplexity = 30 y max_iter = 1000, valores estándar para corpus de tamaño comparable.

2.8 Agregación media-máxima entre licenciaturas

Para resumir la similitud entre dos planes completos A y B en un único número, se utiliza la métrica *similitud media-máxima*:

$$\bar{s}(A, B) = \frac{1}{|A|} \sum_{d \in A} \max_{d' \in B} s(d_i, d_j), \quad (4)$$

donde la suma recorre todas las UEAs del plan A y el máximo se toma sobre todas las UEAs del plan B . La interpretación de la ecuación (4) es: para la UEA *promedio* del plan A , ¿cuán similar es la UEA más parecida que existe en el plan B ?

La elección del operador *max* frente a un promedio global responde a la naturaleza del problema. Un promedio global quedaría dominado por las muchas UEAs sin traslape, diluyendo señales reales de coincidencia. El operador *max* mide si existe una contraparte en B para cada UEA de A —pregunta directamente relevante para la revisión curricular. Esta métrica es asimétrica por diseño: en general $\bar{s}(A, B) \neq \bar{s}(B, A)$, porque un plan B más grande o diverso ofrece más oportunidades de encontrar contrapartes próximas para las UEAs de A . La asimetría es informativamente valiosa: un valor alto de $\bar{s}(A, B)$ con bajo $\bar{s}(B, A)$ indica que el plan A está cubierto por B pero no a la inversa—una relación de inclusión unilateral de contenidos. La diagonal se establece en $\bar{s}(A, B) = 1$ por convención (auto-similitud exacta).

La implementación de todos los pasos metodológicos utiliza la biblioteca *scikit-learn* (Pedregosa et al., 2011), que proporciona las clases *TfidfVectorizer* (ecuaciones (1) y (2)), *cosine_similarity*, *AgglomerativeClustering* (ecuación (3)) y TSNE.

2.9 Enriquecimiento semántico con LLM

La similitud coseno captura traslape léxico pero es ciega a equivalencias semánticas expresadas con vocabulario distinto. Por ejemplo, dos instancias de “Liderazgo y Emprendimiento” en planes diferentes pueden recibir una puntuación TF-IDF baja si sus redacciones difieren, aunque sus contenidos sean idénticos. Para corregir este sesgo, la matriz TF-IDF se enriquece en una segunda fase con evaluación semántica directa por un modelo de lenguaje grande (LLM).

El procedimiento es el siguiente. Primero, se identifican todos los pares con $s_{\text{TF-IDF}} \geq 0.20$ como *candidatos*—un umbral bajo que captura prácticamente todo par con algún vocabulario compartido. Segundo, para cada par candidato se envía al LLM el texto completo del *Objetivo General* y el *Contenido Sintético* de ambas UEAs, junto con una rúbrica de cinco niveles (idéntico, muy alto, alto, moderado, bajo). El modelo devuelve una puntuación $s_{\text{LLM}} \in [0, 1]$ y una breve razón en español. Tercero, la puntuación TF-IDF de cada par candidato se sustituye por s_{LLM} ; los pares no evaluados conservan su puntuación TF-IDF.

Para este corpus se evaluaron 1 505 pares candidatos con 15 llamadas API simultáneas, completando el análisis en 141.6 s a un costo de \$0.24 USD (modelo *claude-haiku-4-5*). El resultado es la *matriz híbrida*: 626×626 entradas donde los pares evaluados por LLM tienen puntuación semántica y el resto conserva la puntuación léxica TF-IDF. De los 1 505 pares evaluados, 455 superaron el umbral $s_{\text{LLM}} \geq 0.40$ con $s_{\text{TF-IDF}} < 0.40$ —pares semánticamente significativos que el análisis léxico habría omitido.

3 Corpus analizado

La tabla 1 muestra la distribución del corpus por licenciatura con las estadísticas de pares similares de la *matriz híbrida*.

Tabla 1: Distribución del corpus y estadísticas de similitud por licenciatura (matriz híbrida TF-IDF + LLM). Los pares inter-plan tienen umbral $s \geq 0.30$; los pares intra-plan, $s \geq 0.40$.

Licenciatura	UEAs	Pares inter-plan		Pares intra-plan	
		Núm.	Máx.	Núm.	Máx.
Ambiental	40	45	1.000	7	0.750
Civil	88	43	1.000	61	0.880
Computación	60	78	0.950	33	0.720
Eléctrica	39	77	0.950	14	0.750
Electrónica	56	89	1.000	8	0.650
Física	60	100	1.000	11	0.950
Industrial	78	87	0.920	18	0.850
Mecánica	108	116	0.950	25	0.850
Metalúrgica	42	48	0.950	29	0.780
Química	55	99	1.000	11	0.990
Total	626	391		217	

La tabla 1 refleja el impacto del enriquecimiento semántico respecto al análisis TF-IDF previo: los pares inter-plan suman 391 (+154 %) y los intra-plan 217 (+75 %). Tres resultados sobresalen. Física encabeza los pares inter-plan con 100, seguida de Mecánica con 116 (que incluye tanto inter como intra) y Química con 99—reflejo de que estas licenciaturas comparten un núcleo de matemáticas, ciencia de materiales y UEAs de formación amplia que TF-IDF infravaloraba. Civil presenta el salto más llamativo en pares intra-plan (de 8 a 61): el LLM detectó que muchas UEAs comparten objetivos en el área de estructuras, hidráulica y materiales que las diferencias de redacción ocultaban. Computación, en cambio, baja de 57 a 33 pares intra-plan: el LLM corrigió falsos positivos generados por TF-IDF con vocabulario genérico de software.

4 Análisis inter-plan

Esta sección analiza la similitud entre UEAs de *distintas* licenciaturas mediante cuatro instrumentos complementarios que responden a preguntas diferentes sobre el mismo corpus: ¿cuánto se parece un plan a otro en conjunto? ¿Cuántas UEAs comparten cada par? ¿Qué UEAs específicas son las más ubicuas? ¿Cuáles son los pares individuales más similares?

4.1 Similitud media-máxima entre planes




Figura 1: Similitud media-máxima $\bar{s}(A, B)$ entre licenciaturas (ecuación (4)). *Cómo leer la figura.* La fila indica el plan de origen A ; la columna, el plan de referencia B . La celda (A, B) responde a: por cada UEA de A , ¿cuán similar es la UEA más parecida que existe en B ? El valor reportado es el promedio de esa similitud máxima sobre todas las UEAs de A . La diagonal es 1 por definición (auto-similitud). *Escala:* amarillo = baja similitud media-máxima; rojo oscuro = alta. *Asimetría:* la celda (A, B) puede diferir de (B, A) cuando los planes difieren en tamaño o diversidad: un plan grande y diverso (como Mecánica, 108 UEAs) ofrece más oportunidades de encontrar contrapartes para las UEAs de cualquier otro plan, elevando la columna correspondiente. Una fila brillante indica que las UEAs de A encuentran contrapartes similares en múltiples planes—señal de que A comparte contenidos ampliamente. *Patrones notables:* el par Ambiental–Química (celda brillante en ambas orientaciones) es el de mayor similitud bilateral; la fila de Física es uniformemente brillante, reflejando su alta conectividad transversal.

4.2 Recuento de UEAs equivalentes: los 45 pares

La figura 2 y la tabla 2 cubren los $\binom{10}{2} = 45$ pares posibles de licenciaturas simultáneamente, mostrando cuántas UEAs comparte cada par a dos umbrales distintos. A diferencia del mapa de calor anterior—que agrega la información en una métrica escalar por par—aquí se cuenta directamente el número de UEAs equivalentes, la magnitud más relevante para la revisión curricular.

Conteo de pares similares inter-plan — DCBI 2026




Figura 2: Número de UEAs equivalentes entre cada par de licenciaturas (los 45 pares). *Cómo leer la figura.* Cada celda (A, B) indica cuántas UEAs del par tienen $s(u_A, u_B) \geq \text{umbral}$; la matriz es simétrica. Las celdas grises en la diagonal (intra-plan) no aplican. El guión “—” indica cero UEAs compartidas al umbral correspondiente. Ambos paneles comparten la misma escala de color (barra derecha, máximo = 38), por lo que los colores son directamente comparables entre paneles. *Panel izquierdo:* umbral $s \geq 0.85$ (equivalencia muy alta). *Panel derecho:* umbral $s \geq 0.70$ (equivalencia alta o mayor). Una celda que retiene su intensidad entre paneles indica que el traslape es mayoritariamente de equivalencia muy alta; una celda que palidece en el panel izquierdo tiene traslape real pero de calidad moderada-alta. *Par dominante:* Industrial–Mecánica con 38 UEAs a $s \geq 0.70$ y 34 a $s \geq 0.85$ —la celda más oscura del corpus en ambos paneles.

Tabla 2: Número de UEAs equivalentes a $s \geq 0.70$ entre cada par de licenciaturas (matriz híbrida TF-IDF + LLM, los 45 pares). Abreviaturas: Amb=Ambiental, Civ=Civil, Cmp=Computación, Elc=Eléctrica, Ele=Electrónica, Fis=Física, Ind=Industrial, Mec=Mecánica, Met=Metalúrgica, Qui=Química.

	Amb	Civ	Cmp	Elc	Ele	Fis	Ind	Mec	Met	Qui
Amb	—	4	1	1	1	5	6	6	2	14
Civ	4	—	6	4	7	9	9	16	3	8
Cmp	1	6	—	7	12	8	4	3	0	1
Elc	1	4	7	—	9	7	5	13	4	4
Ele	1	7	12	9	—	10	11	14	2	2
Fis	5	9	8	7	10	—	14	15	4	9
Ind	6	9	4	5	11	14	—	38	6	13
Mec	6	16	3	13	14	15	38	—	10	14
Met	2	3	0	4	2	4	6	10	—	5
Qui	14	8	1	4	2	9	13	14	5	—

4.3 Red de traslape




Figura 3: Red de traslape entre licenciaturas — pares con ≥ 5 UEAs equivalentes a $s \geq 0.70$ (29 de los 45 pares posibles; los 16 pares con < 5 UEAs no tienen arista). *Cómo leer la figura.* Cada *nodo* representa una licenciatura; su *área* es proporcional al número de UEAs en el corpus (Mecánica = 108 UEAs, el más grande; Eléctrica = 39, el más pequeño; ver escala en la leyenda inferior izquierda). El *color* del nodo identifica la licenciatura (ver leyenda derecha). Cada *arista* conecta dos licenciaturas con ≥ 5 UEAs equivalentes; su *grosor* es proporcional al conteo (escala de aristas en la leyenda: 5, 16 y 38 UEAs). El número **38** anotado sobre la arista entre Industrial y Mecánica indica el conteo máximo del corpus, seis veces mayor que el segundo par más alto. La *posición espacial* (layout Kamada-Kawai, distancia $\propto 1/\text{conteo}$) agrupa automáticamente las licenciaturas con mayor traslape mutuo: el bloque Mecánica-Industrial-Física-Electrónica-Civil converge en el centro; Ambiental y Química quedan juntas en la periferia por su bloque disciplinar compartido. *Ausencia notable:* Computación y Metalúrgica no están conectadas —el único par de los 45 con cero UEAs equivalentes a $s \geq 0.70$.

4.4 UEAs con mayor presencia transversal

La tabla 3 identifica qué UEAs específicas son responsables del traslape inter-plan, agrupando las que aparecen en tres o más licenciaturas con $s \geq 0.70$. La columna n indica el número de licenciaturas; $s_{\text{máx}}$ es la similitud máxima observada en cualquier par de esa UEA. Abreviaturas: Amb=Ambiental, Civ=Civil, Cmp=Computación, Elc=Eléctrica, Ele=Electrónica, Fis=Física, Ind=Industrial, Mec=Mecánica, Met=Metalúrgica, Qui=Química.

Tabla 3: UEA's presentes en tres o más licenciaturas con $s \geq 0.70$ (matriz híbrida). * Familia de UEA's con el mismo contenido pero distintas claves en cada plan; no excluida como TG por el algoritmo de exclusión basado en clave. † Invisible a TF-IDF ($s_{TF} \approx 0.21-0.25$); detectada como equivalente exclusivamente por el LLM.

UEA	n	$s_{\max}$	Licenciaturas
<i>Presentes en 6 o más planes</i>			
Ecuaciones Diferenciales (Ord.)*	9	1.000	Amb, Civ, Elc, Ele, Fis, Ind, Mec, Met, Qui
Liderazgo y Emprendimiento†	9	0.950	Amb, Civ, Cmp, Elc, Ele, Fis, Ind, Mec, Met
Educación Ambiental y Cambio Climático	6	1.000	Civ, Elc, Ele, Fis, Mec, Qui
Taller de Comunicación Técnica y Prof.	6	0.990	Civ, Cmp, Ele, Fis, Ind, Mec
<i>Presentes en 5 planes</i>			
Cálculo Integral	5	1.000	Civ, Cmp, Ele, Fis, Mec
Gestión y Seguimiento de Proyectos	5	1.000	Cmp, Elc, Ele, Fis, Ind
Estructura y Prop. de los Materiales	5	0.980	Amb, Fis, Ind, Mec, Qui
Métodos Numéricos en Ingeniería	5	0.980	Civ, Elc, Mec, Met, Qui
Probabilidad y Estadística Descr.	5	0.980	Civ, Ele, Fis, Ind, Mec
Programación Aplic. a la Ingeniería	5	0.980	Civ, Fis, Ind, Mec, Met
<i>Presentes en 4 planes</i>			
Herramientas Digitales en Ingeniería	4	1.000	Civ, Fis, Ind, Qui
Lab. de Estr. y Prop. de Materiales	4	0.980	Fis, Ind, Mec, Qui
Energía Solar Fotovoltaica	4	0.980	Elc, Fis, Ind, Mec
Diseño Digital	4	0.980	Cmp, Elc, Ele, Mec
<i>Presentes en 3 planes con $s = 1.00$</i>			
Análisis de Ciclo de Vida	3	1.000	Amb, Civ, Qui
Ingeniería Económica	3	1.000	Ind, Mec, Qui
Seguridad e Higiene Industrial	3	1.000	Ind, Mec, Qui
Análisis de Costos para Toma de Dec.	3	1.000	Elc, Ind, Mec
Evaluación de Proyectos en Ing.	3	1.000	Ele, Ind, Mec
Dibujo Asistido por Computadora	3	1.000	Civ, Ele, Elc

4.5 Pares individuales de mayor similitud

La tabla 4 lista los veinte pares de UEA's individuales con mayor puntuación en la matriz híbrida. $s = 1.00$ indica equivalencia textual; $s \geq 0.92$ indica equivalencia semántica muy alta.

Tabla 4: Veinte pares inter-plan de mayor similitud (matriz híbrida TF-IDF + LLM). $s = 1.00$: programas con contenido textualmente idéntico. $s \geq 0.92$: equivalencia semántica muy alta confirmada por el LLM.

Sim.	Nombre de la UEA	Lic. A	Lic. B
1.000	Análisis de Ciclo de Vida	Ambiental	Química
1.000	Manejo y Tratam. de Residuos Ind.	Ambiental	Química
1.000	Educación Ambiental y Cambio Clim.	Civil	Química
1.000	Ecuaciones Diferenciales	Electrónica	Física
0.980	Análisis de Ciclo de Vida	Ambiental	Química
0.980	Procesos Biológicos en Ing. Amb.	Ambiental	Química
0.980	Educación Ambiental y Cambio Clim.	Electrónica	Química
0.980	Lab. Estructura y Prop. Mat.	Física	Química
0.950	Microbiología Aplicada	Ambiental	Química
0.950	Estructura y Prop. de Materiales	Ambiental	Química
0.950	Legislación y Gestión Ambiental	Ambiental	Química
0.950	Mecánica de Fluidos	Ambiental	Química
0.950	Ecuaciones Diferenciales Ordinarias	Civil	Mecánica
0.950	Análisis de Ciclo de Vida	Civil	Química
0.950	Álgebra Lineal	Computación	Física
0.950	Ética, Respons. Social y Sost.	Computación	Física
0.950	Estadística	Computación	Física
0.950	Liderazgo y Emprendimiento	Computación	Física
0.950	Educación Ambiental y Cambio Clim.	Eléctrica	Química
0.920	Ing. de los Materiales	Industrial	Metalúrgica

Los veinte pares de la tabla 4 concentran cuatro fenómenos distintos. El bloque Ambiental–Química domina la parte superior con ocho pares (y una docena adicional con $s \geq 0.70$ no mostrados). “Educación Ambiental y Cambio Climático” aparece en tres instancias en la tabla y está presente en al menos seis planes (tabla 3). La fila Computación–Física agrupa cuatro UEAs de formación amplia (Álgebra Lineal, Ética, Estadística, Liderazgo) con $s = 0.95$. El par Civil–Mecánica en Ecuaciones Diferenciales Ordinarias introduce el núcleo matemático transversal documentado en la tabla 3.

5 Análisis intra-plan

Esta sección analiza la similitud entre UEAs *dentro de un mismo plan*. Alta similitud intra-plan puede deberse a causas legítimas—una pareja taller/teoría del mismo nombre base es un par esperado—o a causas problemáticas: UEAs de distinto nivel con contenido no diferenciado, o duplicaciones documentales.

5.1 Pares y casos más relevantes

Tabla 5: Quince pares intra-plan de mayor similitud (matriz híbrida TF-IDF + LLM). † pareja taller/teoría confirmada como legítima por el LLM. Sin marca: par que requiere revisión curricular.

Sim.	UEA A	Lic.	UEA B
0.990	Análisis de Ciclo de Vida	Química	Análisis de Ciclo de Vida (dup.)
0.950	Aplic. Exp. Ing. Física I	Física	Aplic. Exp. Ing. Física II
0.880	Taller Inv. en Ing. Civil I	Civil	Taller Inv. en Ing. Civil II
0.850 [†]	Lab. de Metrología para Manufactura	Industrial	Metrología para Manufactura
0.850 [†]	Lab. de Eficiencia Operativa	Industrial	Medición del Trabajo p. Eficiencia
0.850 [†]	Taller de Tecn. de Conformado	Industrial	Tecn. de Conformado y Ensamble
0.850 [†]	Lab. de Mecanismos	Mecánica	Mecanismos
0.850 [†]	Proy. Mecánico de Montajes	Mecánica	Taller Proy. Mecánico de Montajes
0.850 [†]	Lab. de Eficiencia Operativa	Mecánica	Medición del Trabajo p. Eficiencia
0.820	Elementos de Acero	Civil	Diseño de Estructuras de Acero
0.780 [†]	Estructura y Prop. de Materiales	Industrial	Lab. de Estr. y Prop. de Mat.
0.780 [†]	Estructura y Prop. de Materiales	Mecánica	Lab. de Estr. y Prop. de Mat.
0.780 [†]	Taller de Tecn. de Conformado	Mecánica	Tecn. de Conformado y Ensamble
0.780 [†]	Calefacción, Vent. y Aire Acond.	Mecánica	Taller de CVAA
0.780 [†]	Tratamientos Térmicos de Mat.	Metalúrgica	Lab. de Tratamientos Térmicos

Los tres primeros pares de la tabla 5 son casos problemáticos; los doce restantes son parejas taller/teoría confirmadas como legítimas por el LLM.

Caso 1: Química — duplicado de “Análisis de Ciclo de Vida” ($s = 0.990$). El corpus contiene dos documentos con el mismo título y contenido. Debe determinarse cuál es el programa vigente y retirarse el duplicado del repositorio.

Caso 2: Física — “Aplic. Exp. Ing. Física I” y “II” ($s = 0.950$). Dos UEAs consecutivas de laboratorio evaluadas como *idéntico* por el LLM. O bien los campos de Objetivo General y Contenido Sintético no han sido diferenciados entre niveles, o bien se trata de una duplicación documental.

Caso 3: Civil — Taller de Investigación I vs. II ($s = 0.880$). Dos instancias del mismo tipo de actividad en trimestres consecutivos sin diferenciación de programa. Civil concentra 61 pares intra-plan a $s \geq 0.40$ (el mayor del corpus): el LLM detectó que las áreas de estructuras, hidráulica, geotecnia y materiales comparten objetivos convergentes redactados independientemente por departamentos distintos.

Caso adicional — Industrial: duplicado de “Herramientas Digitales en Ingeniería” (clave 1100202). Dos documentos con la misma clave y contenido en el corpus de Industrial. No aparece en la tabla 5 porque la detección automática excluye pares con clave idéntica; fue identificado mediante el mapa de calor intra-plan.

5.2 Mapas de calor intra-plan

Las figuras 4–13 son los mapas de calor intra-plan de las diez licenciaturas, ordenados de mayor a menor densidad de traslape.

Cómo leer los mapas. Filas y columnas corresponden a las UEAs del plan, reordenadas por agrupamiento jerárquico de Ward: las UEAs de contenido similar quedan contiguas. *Diagonal*: siempre 1 (auto-similitud); una franja roja continua en la diagonal sin bloques off-diagonal indica plan bien

diferenciado. *Bloque compacto cerca de la diagonal*: grupo de UEAs temáticamente afines (por ejemplo, un área disciplinar con varias materias relacionadas o una secuencia taller/teoría). *Celda brillante aislada fuera de la diagonal*: par puntual de alta similitud—puede ser una pareja taller/teoría legítima o un duplicado problemático. *Escala*: amarillo claro = baja similitud; rojo intenso = alta. Los planes con más de 55 UEAs se presentan sin etiquetas de eje (ilegibles a textwidth); la versión interactiva identifica cada UEA al pasar el cursor.

Civil (88 UEAs, 61 pares con $s \geq 0.40$). La licenciatura con mayor densidad de traslape intra-plan del corpus. El mapa muestra múltiples bloques de color intenso distribuidos en la diagonal, correspondientes a grupos de estructuras, hidráulica y materiales con objetivos convergentes. La celda más brillante corresponde a Taller de Investigación I vs. II ($s = 0.880$, Caso 3); Elementos de Acero/Diseño de Estructuras de Acero ($s = 0.820$) es el par teoría/aplicación más significativo.



Figura 4: Similitud intra-plan — Civil (88 UEAs, 61 pares con $s \geq 0.40$). La alta densidad de bloques en la diagonal refleja objetivos convergentes en las áreas de estructuras, hidráulica, geotecnia y materiales—redactados independientemente por departamentos distintos y detectados como equivalentes por el LLM (TF-IDF reportaba solo 8 pares). La celda más brillante: Taller Inv. Civil I vs. II ($s = 0.880$, Caso 3). Ver `intraplan_Civil.html` para identificar UEAs individuales.

Metalúrgica (42 UEAs, 29 pares con $s \geq 0.40$). El mayor incremento relativo del corpus: de 3 pares (TF-IDF) a 29 (LLM). El vocabulario técnico especializado de Metalúrgica es heterogéneo entre versiones del mismo programa, lo que impedía la detección léxica; el LLM reconoció la equivalencia semántica. Los 29 pares son en su totalidad parejas taller/teoría o áreas afines; no se identifican duplicados ni pares problemáticos. El par más alto es Lab. de Tratamientos Térmicos/Tratamientos Térmicos de los Materiales ($s = 0.780$).




Figura 5: Similitud intra-plan — Metalúrgica (42 UEAs, 29 pares con $s \geq 0.40$). El patrón de bloques en la diagonal corresponde a parejas taller/teoría del área de materiales y procesos (tratamientos térmicos, metalografía, soldadura). El salto de 3 a 29 pares respecto a TF-IDF refleja vocabulario técnico heterogéneo entre versiones del mismo programa, no duplicados.

Computación (60 UEAs, 33 pares con $s \geq 0.40$). El LLM redujo los pares de 57 (TF-IDF) a 33, descartando 24 artefactos léxicos del vocabulario genérico de software. Se distinguen dos bloques de traslape genuino: el área de *bases de datos* (Relacional, No Relacional, Distribuida) y el área de *redes* (Redes de Computadoras, Administración, Seguridad, Automatización). El par Programación Orientada a Objetos I vs. II permanece como el par no-taller más preocupante.

Computación — similitud intra-plan
60 UEAs · 33 pares con $s \geq 0.40$




Figura 6: Similitud intra-plan — Computación (60 UEAs, 33 pares con $s \geq 0.40$). Se distinguen dos bloques de traslape genuino: el área de bases de datos (tres UEAs con objetivos solapados) y el área de redes (cuatro UEAs afines). El punto brillante aislado en la esquina corresponde a POO I vs. II. TF-IDF reportaba 57 pares; el LLM descartó 24 como falsos positivos atribuibles a vocabulario genérico de desarrollo de software. Ver [intraplan_Computacion.html](#) para identificar UEAs individuales.

Mecánica (108 UEAs, 25 pares con $s \geq 0.40$). El plan más extenso del corpus. La mayor parte del mapa es de color frío, indicando que los 108 contenidos están bien diferenciados para un plan de esta magnitud. Los 25 pares son todas parejas taller/laboratorio esperadas: Lab. de Mecanismos/Mecanismos ($s = 0.85$), Lab. de Eficiencia Operativa/Medición del Trabajo ($s = 0.85$), Lab. Estructura y Prop./Estructura y Prop. de Mat. ($s = 0.78$), Taller de CVAA/CVAA ($s = 0.78$).




Figura 7: Similitud intra-plan — Mecánica (108 UEAs, 25 pares con $s \geq 0.40$). La mayor parte del mapa es de color frío: plan amplio con contenidos bien diferenciados. Los únicos bloques de color corresponden a parejas taller/laboratorio con el mismo nombre base (Lab. de Mecanismos / Mecanismos, CVAA / Taller de CVAA, etc.), todos confirmados como legítimos por el LLM. No se identifican duplicados ni pares problemáticos. Ver [intraplan_Mecanica.html](#) para identificar UEAs individuales.

Física (60 UEAs, 11 pares con $s \geq 0.40$). La celda más brillante fuera de la diagonal corresponde al duplicado de programas entre Aplicaciones Experimentales de Ingeniería Física I y II ($s = 0.950$, Caso 2). Los 10 pares restantes son principalmente combinaciones de UEAs de cómputo científico y laboratorio experimental.




Figura 8: Similitud intra-plan — Física (60 UEAs, 11 pares con $s \geq 0.40$). El punto más brillante fuera de la diagonal es el par Aplicaciones Experimentales I vs. II ($s = 0.950$, Caso 2): dos UEAs consecutivas de laboratorio con programas no diferenciados. Los pares restantes corresponden a UEAs de cómputo científico y laboratorio. Ver [intraplan_Fisica.html](#) para identificar UEAs individuales.

Química (55 UEAs, 11 pares con $s \geq 0.40$). El máximo intra-plan de Química ($s = 0.990$) es el más alto de todas las licenciaturas, correspondiente al duplicado documental de Análisis de Ciclo de Vida (Caso 1). Los 10 pares restantes incluyen parejas teoría/laboratorio y secuencias de contenidos afines.




Figura 9: Similitud intra-plan — Química (55 UEAs, 11 pares con $s \geq 0.40$). El punto más brillante fuera de la diagonal ($s = 0.990$) es el duplicado documental de *Análisis de Ciclo de Vida* (Caso 1): mismo contenido en dos instancias del repositorio. Los demás pares son secuencias teoría/laboratorio esperadas.

Industrial (78 UEAs, 18 pares con $s \geq 0.40$). Los 18 pares son en su mayoría parejas taller/teoría confirmadas: Lab. de Metrología ($s = 0.85$), Lab. de Conformado ($s = 0.85$), Lab. de Eficiencia Operativa ($s = 0.85$), Lab. Estructura de Materiales ($s = 0.78$). El punto más brillante fuera de las parejas taller/teoría corresponde al duplicado de Herramientas Digitales en Ingeniería (caso adicional).




Figura 10: Similitud intra-plan — Industrial (78 UEAs, 18 pares con $s \geq 0.40$). Los bloques de la diagonal corresponden a parejas taller/teoría del área de manufactura (metrología, conformado, eficiencia operativa). El punto más brillante fuera de la diagonal es el duplicado de *Herramientas Digitales en Ingeniería* (clave 1100202), identificado mediante el mapa de calor al no ser detectable por la comparación automática (clave idéntica). Ver `intraplan_Industrial.html` para identificar UEAs individuales.

Eléctrica (39 UEAs, 14 pares con $s \geq 0.40$). El LLM redujo los pares de 27 (TF-IDF) a 14, descartando pares atribuibles al vocabulario electromagnético compartido por Circuitos, Teoría Electromagnética y Cálculo Vectorial. El par más significativo es Estructura de Materiales/Laboratorio de Estructura y Electroquímica ($s = 0.75$, pareja taller/teoría confirmada).




Figura 11: Similitud intra-plan — Eléctrica (39 UEAs, 14 pares con $s \geq 0.40$). TF-IDF reportaba 27 pares; el LLM confirmó 14 como equivalencias reales y descartó 13 atribuibles al vocabulario de campo electromagnético compartido por Circuitos, Teoría Electromagnética y Cálculo Vectorial sin equivalencia de contenidos.

Ambiental (40 UEAs, 7 pares con $s \geq 0.40$). Traslape intra-plan bajo-moderado; los 7 pares corresponden a UEAs del área de gestión ambiental con objetivos semánticamente afines y redacciones heterogéneas. Contrasta con el traslape inter-plan intenso con Química (14 UEAs a $s \geq 0.70$): los contenidos de Ambiental están bien diferenciados internamente, pero se solapan significativamente con los de Química.




Figura 12: Similitud intra-plan — Ambiental (40 UEAs, 7 pares con $s \geq 0.40$, máx. $s = 0.750$). El mapa es predominantemente de color frío: plan compacto con contenidos diferenciados internamente. Los 7 pares son UEAs del área de gestión ambiental con objetivos afines. *Contraste:* el traslape significativo de Ambiental es inter-plan, hacia Química (14 UEAs a $s \geq 0.70$, sección 4).

Electrónica (56 UEAs, 8 pares con $s \geq 0.40$). Electrónica tiene la menor densidad de traslape intra-plan del corpus, con 8 pares (máximo $s = 0.650$). Sus contenidos están bien diferenciados internamente. Sin embargo, su traslape inter-plan es intenso: 89 pares con otras licenciaturas, incluyendo pares con $s = 1.00$.




Figura 13: Similitud intra-plan — Electrónica (56 UEAs, 8 pares con $s \geq 0.40$, máx. $s = 0.650$). El mapa es casi completamente de color frío: plan bien diferenciado internamente. *Contraste:* Electrónica es uno de los planes con mayor traslape *inter-plan* (89 pares con otras licenciaturas, incluyendo $s = 1.00$)—sus UEAs son distintas entre sí pero equivalentes a UEAs de otros planes. Ver `intraplan_Electronica.html` para identificar UEAs individuales.

6 Mapa de calor agrupado




Figura 14: Mapa de calor agrupado: submatriz de similitud coseno para las 120 UEAs con mayor conectividad ($s \geq 0.35$), reordenadas por agrupamiento jerárquico de Ward. *Cómo leer la figura.* Barra lateral izquierda: codifica la licenciatura de cada UEA por color. *Bloques rojos/naranja en la diagonal:* comunidades de contenido—grupos de UEAs que comparten vocabulario técnico. Si dentro de un bloque la barra lateral muestra múltiples colores, el traslape es inter-plan. *Rectángulos brillantes fuera de la diagonal:* traslape bilateral entre dos comunidades distintas; la intensidad es proporcional a la similitud. *Regiones frías* (amarillo pálido/blanco): independencia de contenido. El bloque más rojo del mapa corresponde a la comunidad Ambiental–Química. Ver [heatmap_clustered.html](#) para identificar UEAs individuales.

Del mapa agrupado se distinguen tres comunidades de contenido.

Comunidad I: ingeniería ambiental compartida. El bloque más compacto e intenso del mapa, con barras de dos colores (Ambiental y Química), confirma el traslape bilateral documentado en la tabla 2.

Comunidad II: fenómenos de transporte y ciencia de materiales. Agrupa UEAs de transferencia de calor, transferencia de masa, mecánica de fluidos y termodinámica de los planes de Mecánica, Química, Ambiental e Industrial. La diversidad de colores en la barra lateral evidencia el traslape inter-plan dentro de esta comunidad.

Comunidad III: matemáticas e ingeniería eléctrica/electrónica. Agrupa ecuaciones diferenciales, métodos numéricos y UEAs de circuitos de los planes de Eléctrica, Electrónica y Física. Corresponde al núcleo matemático transversal de la tabla 3.

7 Proyección t-SNE



Figura 15: Proyección t-SNE del corpus completo (626 UEAs). *Cómo leer la figura.* Cada *punto* es una UEA, coloreado por licenciatura. *Proximidad:* dos puntos cercanos comparten vocabulario técnico, independientemente de la licenciatura de origen. Un punto de color X rodeado de puntos de color Y indica una UEA de X con contenido similar al de varias UEAs de Y . *Líneas grises:* conectan pares inter-plan con $s \geq 0.70$. Su brevedad confirma que t-SNE coloca las UEAs equivalentes como vecinas inmediatas en el plano. *Clusters:* los grupos compactos corresponden a las comunidades disciplinares (ambiental/química, materiales, matemáticas/eléctrica/electrónica). *Advertencia:* la distancia entre clusters alejados *no es interpretable*—t-SNE preserva vecindades locales, no distancias globales. Ver `scatter_tsne.html` para identificar UEAs individuales.

Los clusters visibles en la figura 15 son coherentes con las comunidades identificadas en el mapa de calor agrupado: un grupo denso en la zona de Ambiental/Química, un bloque de UEAs matemáticas con puntos de múltiples licenciaturas superpuestos, y una región de Electrónica/Eléctrica/Física. Las líneas grises cortas confirman que las UEAs con $s \geq 0.70$ son vecinas en el espacio de contenidos.

8 Hallazgos principales

8.1 Hallazgos inter-plan

Hallazgo H1. Industrial–Mecánica: par de máxima densidad de traslape. 38 UEAs compartidas a $s \geq 0.70$; 34 a $s \geq 0.85$. Ningún otro par supera 16 UEAs a $s \geq 0.70$. El traslape cubre manufactura, materiales, termodinámica, diseño de elementos, métodos numéricos, gestión de operaciones y UEAs de formación amplia (ética, liderazgo, comunicación). La magnitud sugiere que ambos planes comparten implícitamente al menos un tercio de sus UEAs no-TG.

Hallazgo H2. Física: nodo de máxima conectividad transversal. Física comparte UEAs con todas las demás licenciaturas sin excepción: 15 con Mecánica, 14 con Industrial, 10 con Electrónica, 9 con Civil y Química, 8 con Computación, 7 con Eléctrica, 5 con Ambiental, 4 con Metalúrgica. Con 100 pares inter-plan a $s \geq 0.30$, encabeza el corpus en conectividad transversal.

Hallazgo H3. Bloque de ingenierías clásicas. Mecánica, Industrial, Física y Electrónica forman un bloque con ≥ 10 UEAs compartidas entre cada par a $s \geq 0.70$. Civil se acopla fuertemente a Mecánica (16 UEAs) y se sitúa en la periferia de este bloque. La densidad del bloque explica la mayor parte del traslape inter-plan del corpus.

Hallazgo H4. Ambiental–Química: núcleo de ingeniería ambiental implícito. 14 UEAs compartidas a $s \geq 0.70$ (segunda densidad más alta del corpus, tras Industrial–Mecánica), con 9 a $s \geq 0.85$. El conjunto incluye Análisis de Ciclo de Vida, Legislación y Gestión Ambiental, Manejo de Residuos, Procesos Biológicos, Microbiología Aplicada, Mecánica de Fluidos, Estructura y Propiedades de Materiales, entre otros. El grado de coincidencia supera lo atribuible a vocabulario disciplinar compartido.

Hallazgo H5. Ecuaciones Diferenciales: Tronco General implícito léxico (9 de 10 planes). La familia de UEAs de Ecuaciones Diferenciales (Ordinarias) aparece en 9 licenciaturas con $s \geq 0.70$, bajo distintas claves en cada plan. No fue excluida como Tronco General porque el criterio de exclusión opera por clave. Es de facto una UEA del Tronco General sin serlo formalmente.

Hallazgo H6. Liderazgo y Emprendimiento: Tronco General implícito semántico (9 de 10 planes). Contenido prácticamente idéntico en 9 licenciaturas, confirmado por el LLM ($s_{LLM} \geq 0.72$). TF-IDF le asignaba $s_{TF} \approx 0.21$ – 0.25 porque su vocabulario—liderazgo, comunicación, trabajo en equipo, innovación—es genérico y filtra como baja discriminación. Es el ejemplo más claro de equivalencia curricular estructuralmente indetectable por análisis léxico.

Hallazgo H7. Educación Ambiental y Cambio Climático: programa idéntico en 6 o más planes. Presente con $s \geq 0.95$ en Civil, Eléctrica, Electrónica, Física, Mecánica y Química. La presencia en Ambiental, Industrial y Metalúrgica no ha sido verificada. Candidata a elevarse a Tronco General o a coordinación institucional explícita.

Hallazgo H8. Núcleo matemático transversal (5 planes cada uno). Cálculo Integral, Probabilidad y Estadística Descriptiva, Métodos Numéricos en Ingeniería y Programación Aplicada a la Ingeniería aparecen en 5 licenciaturas con $s \geq 0.98$. Junto con Ecuaciones Diferenciales (H5), conforman cinco UEAs matemáticas que cruzan la mayoría de los planes sin estar formalmente en el Tronco General.

Hallazgo H9. Computación–Metalúrgica: única combinación sin traslape. El único par de los 45 posibles con cero UEAs equivalentes a $s \geq 0.70$. Máxima distancia curricular del corpus: los contenidos de ambas licenciaturas son ortogonales en el espacio de contenidos declarados.

8.2 Hallazgos intra-plan

Hallazgo H10. Duplicados documentales identificados. Tres casos de documentos duplicados detectados por la matriz híbrida:

- *Química*: Análisis de Ciclo de Vida, $s = 0.990$ (mismo contenido, dos instancias en el repositorio).
- *Física*: Aplicaciones Experimentales I y II, $s = 0.950$ (programas no diferenciados entre niveles consecutivos).
- *Industrial*: Herramientas Digitales en Ingeniería, clave 1100202 duplicada (identificado por mapa de calor intra-plan; no detectable por comparación automática).

Hallazgo H11. Civil: mayor densidad intra-plan (61 pares, $s \geq 0.40$). TF-IDF reportaba 8 pares; el LLM detectó 61. Las áreas de estructuras, hidráulica, geotecnia y materiales del plan de Ingeniería Civil contienen objetivos convergentes redactados independientemente por departamentos distintos.

Hallazgo H12. Computación: corrección de 24 falsos positivos. TF-IDF reportaba 57 pares intra-plan; el LLM confirmó 33. Los 24 pares descartados eran artefactos del vocabulario genérico de desarrollo de software. Los 33 confirmados incluyen POO I vs. II y clusters de redes y bases de datos con diferenciación pedagógica insuficiente.

Hallazgo H13. Metalúrgica: mayor incremento relativo (3 → 29 pares). El vocabulario técnico heterogéneo entre versiones del mismo programa impedía la detección léxica. El LLM reconoció la equivalencia semántica en 26 pares adicionales, todos parejas taller/teoría o áreas afines; no se identifican casos problemáticos.

Hallazgo H14. Impacto del enriquecimiento semántico LLM. Sobre 1 505 pares candidatos a un costo de \$0.24 USD:

- 455 pares nuevos con $s_{LLM} \geq 0.40$ que TF-IDF habría omitido ($s_{TF} < 0.40$).
- Pares inter-plan detectados ($s \geq 0.30$): 154 → 391 (+154 %).
- Pares intra-plan detectados ($s \geq 0.40$): 124 → 217 (+75 %).

9 Observaciones y recomendaciones

De los hallazgos de la sección 8 se desprenden cinco líneas de acción para las coordinaciones de licenciatura y las instancias de revisión curricular de la División.

1. Corrección de duplicados documentales (H10). Los tres casos identificados—Análisis de Ciclo de Vida en Química, Aplic. Experimentales I/II en Física, y Herramientas Digitales en Industrial—requieren revisión documental inmediata: determinar cuál es el programa vigente y retirar el duplicado del repositorio.

2. Verificación del alcance de “Educación Ambiental y Cambio Climático” (H7). La UEA aparece con $s \geq 0.95$ en seis licenciaturas; debe verificarse su presencia en Ambiental, Industrial y Metalúrgica. Si se confirma, el hallazgo debe elevarse a las instancias de revisión curricular para determinar el tratamiento institucional correspondiente.

3. Revisión del estatus de Ecuaciones Diferenciales y Liderazgo y Emprendimiento como Tronco General implícito (H5, H6). Ambas UEAs tienen presencia en 9 de 10 planes con contenido prácticamente idéntico—equivalente al Tronco General formal—pero no están clasificadas como tal. Se recomienda un análisis institucional que determine si procede su incorporación explícita al Tronco General o la adopción de un mecanismo de coordinación equivalente.

4. Revisión del núcleo disciplinar Ambiental–Química y del traslape intra-plan de Civil (H4, H11). El bloque Ambiental–Química concentra más de 14 UEAs equivalentes a $s \geq 0.70$. Civil registra 61 pares intra-plan, atribuibles a objetivos convergentes redactados independientemente. En ambos casos se recomienda examinar si el traslape responde a una decisión curricular explícita o es resultado no intencional, y documentarlo a través de los mecanismos que la División considere pertinentes.

5. Diferenciación de contenidos en Computación (H12). Los 33 pares intra-plan confirmados incluyen casos de diferenciación pedagógica insuficiente: POO I vs. II y los clusters de redes y bases de datos. Se recomienda una revisión específica del plan de Computación para establecer diferenciación clara entre UEAs consecutivas y entre UEAs de áreas temáticas próximas.

Nota Las métricas de este reporte se basan exclusivamente en el texto de los campos *Objetivo General* y *Contenido Sintético* de los programas de UEA tal como están registrados en los documentos del repositorio DCBI 2026. Una similitud baja no implica que dos UEAs no compartan bibliografía o metodologías; una similitud alta no implica que las UEAs deban fusionarse, sino que sus contenidos declarados requieren revisión y diferenciación explícita.

Referencias

- Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- Fionn Murtagh and Pierre Legendre. Ward's hierarchical agglomerative clustering method: Which algorithms implement Ward's criterion? *Journal of Classification*, 31(3):274–295, 2014.
- Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- Stephen Robertson. Understanding inverse document frequency: On theoretical arguments for IDF. *Journal of Documentation*, 60(5):503–520, 2004.

- Gerard Salton and Christopher Buckley. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5):513–523, 1988.
- Gerard Salton and Michael J. McGill. *Introduction to Modern Information Retrieval*. McGraw-Hill, 1983.
- Karen Sparck Jones. A statistical interpretation of term specificity and its application in retrieval. *Journal of Documentation*, 28(1):11–21, 1972.
- Peter D. Turney and Patrick Pantel. From frequency to meaning: Vector space models of semantics. *Journal of Artificial Intelligence Research*, 37:141–188, 2010.
- Laurens van der Maaten and Geoffrey E. Hinton. Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9:2579–2605, 2008.
- Jr. Ward, Joe H. Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association*, 58(301):236–244, 1963.
- Martin Wattenberg, Fernanda Viégas, and Ian Johnson. How to use t-SNE effectively. *Distill*, 2016. doi: 10.23915/distill.00002.